

评论区 AI 助手（@爱小奇）策略文档

一、需求概述

在视频评论区新增 @爱小奇 功能。用户发送「@爱小奇 + 问题」，AI 以评论回复形式作答。

评论区是新的内容消费场景，不是新的能力——用户问的问题（剧情、集数、主演、找片）由现有技术覆盖。需要新建的是场景适配层：输入识别、输出约束、缓存隔离，以及通往 AI 助手页的承接路径。

skills_v2 目录共 40 个主技能，评论区从中选出 14 个纳入白名单，其余 26 个排除（排除理由和完整清单见 3.4）。

二、交互形态

2.1 三种情况，两种跳转

评论区回复必须简短，且无法展示作品卡。超出展示长度的部分、被滤掉的作品卡，以及评论区无法承接的问题，都通过跳转链导向 AI 助手页。

跳转分两种行为：能承接的问题带着「原始问题 + 回复原文」过去直接展示，作品卡片在 AI 助手页完整渲染；不能承接的问题只带「原始问题」过去重新提问。

情况	评论区展示	跳转行为
能答，回复短且无作品卡	完整回复，无跳转链	—
能答，回复超长或含作品卡	截断 + 「去 AI 助手看完整回复」	跳转 B： 带原问题 + 回复原文，直接展示问答对，渲染作品卡
评论区不支持	固定拒答话术 + 「去 AI 助手里试试」	跳转 A： 仅带原问题，AI 助手重新作答

两种跳转的差异在于 AI 助手页是展示原有内容还是重新生成。跳转 B 展示的是评论区那条回复的原文（含作品卡），用户看到的内容与评论区一致、只是更完整；跳转 A 因评论区没有答案，只能重新提问。

2.2 跳转 B 的处理逻辑

完整回复信息，包括作品卡占位符 `{{qipuid:123}}` 会原样下发到客户端。评论区展示时过滤掉占位符，只展示作品名。跳转时把未过滤的原文带给 AI 助手页，AI 助手页完整展示（含作品卡渲染）。

2.3 截断由前端处理

截断在前端做：超过展示阈值即截断并追加跳转链。服务端只负责把答案控制在生成上限内，不做硬截断——当前系统各技能的字数限制都通过 Prompt 实现，评论区沿用同一模式。

生成上限：问答类 150 字、展示 100 字；列表类生成约 220 字、展示 2~3 条（详见 3.5）。超出展示阈值的部分是跳转 B 的价值来源，用户点进 AI 助手页才能看到完整回复。

三、评论区支持的问题类型

3.1 技能白名单（14 个）

技能	覆盖问题	评论区适配
movie-qa	剧情、评价、结局、分集梗概	A 档格式（1~3 句直答）天然适配
movie-fact	集数、主演、上线时间、可看性	不挂 refIndex，最接近纯文本
plot-point	单处桥段/台词的集数定位	规范已限定 1~3 句、禁分区
movie-identify	按剧情线索找未知名作品	直接可用
movie-recommend-similar	找相似作品	展示条数收敛，见 3.5
movie-recommend-genre	按题材/演员找片	展示条数收敛
movie-recommend-trending	最新/最热推荐	展示条数收敛
series-franchise	系列有几季、某季在哪看	格式需覆盖，见 3.2，第二阶段上线
movie-theater-scenarios	六大剧场找片	展示条数收敛
casual-chat	问候、寒暄、简单情绪回应	需收窄能力范围，见 3.2
celebrity-search	明星档案与代表作	直接可用
movie-clips	名场面、花絮合集	展示条数收敛
general-web-answer	通用兜底	直接可用
sensitive-topic	敏感内容拦截	固定话术拒答

3.2 三个需要额外处理的白名单技能

series-franchise（系列/IP 检索）

纳入理由：用户在《庆余年 2》评论区问「第三季什么时候出」「前两季在哪看」是最高频问法之一，而其他白名单技能都答不对——movie-fact 只答单部事实，荐片类不做系列图谱。缺它会导致路由到相邻技能后答错：漏季、或把系列名当成单片来讲。

movie-theater-scenarios（剧场找片）

场景契合度高：迷雾剧场剧集的评论区问「迷雾剧场还有什么好剧」，问的正是当前作品所属的内容集合，与观看语境直接相关。格式冲突与荐片类同类（技能要求按共性分 2~4 组、每组 2~3 部、总量 6~10 部，且每部必须挂 refIndex 标号），复用荐片类的同一套条数与格式收敛规则。

casual-chat（闲聊）

评论区「@爱小奇 你好」「你觉得这剧怎么样」属高频发言，没有兜底会全部落到拒答。

必须收窄的能力范围：禁用角色扮演与 MBTI 性格分析，只保留问候告别、日常寒暄、简单情绪回应。

- **角色扮演：**需要用户提供人格设定，在公开评论区是内容安全暴露面（诱导性设定会被公开展示），且与观剧语境无关。
- **MBTI 性格分析：**多轮追问型玩法，一次分析需要来回问答，会在单个评论楼层堆出长对话串，破坏楼层浏览体验。

3.3 两个明确不纳入的技能

trending-topics（热点事件）

内容边界不可控：技能覆盖范围包含「战争冲突、国际局势、社会新闻、政策变化与舆情影响」。一条国际时局或社会新闻的回复出现在剧集评论区，是公开可见的跨领域内容暴露面，与评论区的观剧语境无关。

celebrity-gossip（明星问答）

技能规范明确允许「未经证实的信息标注『据传』『有网友爆料』」。这个规则在一对一问答里是合理的免责声明，在公开可见的评论区则性质不同：平台以官方身份输出带「据传」的明星传闻，等同于官方渠道传播未核实信息。

评论区是粉丝聚集地，八卦类回复极易引发粉丝对立、拉踩和举报，一条回复的负面影响面远大于一对一场景。

3.4 排除的技能（26 个）

白名单 14 个，排除 26 个，合计 40 个主技能。排除技能按原因分四类：

端上执行类（8 个）：play-album、play-clips、cast-screen、download-service、sleep-timer、follow-album、subscribe-album、register-service。评论区无法执行端上动作。

个人数据类（3 个）：battle-report、movie-recommend-personalized、user-playlist。评论区是公共区域，不适合推个性化内容。battle-report 观影战报可以再评估，若放开需考虑刷楼风险。

场景无关类（13 个）：member-service、consumer-service、taodou-world、live-service、wallpaper-service、weather-service、iqiyi-account-search、calendar-service、ai-playlist、short-video-search、movie-play-external、trending-topics、celebrity-gossip。不属于评论区讨论语境，或能力已被白名单覆盖。其中 calendar-service（追剧日历）后续可优化回复内容后考虑放开。

形态不适配类（2 个）：

- `episode-intro` — 强依赖「半播页 + @剧集介绍触发词 + 场景 episodeld」，缺一即回「当前页面不支持此功能」；输出带固定标题与跳转链接列表，是半播页卡片形态。评论区的「这集讲什么」由 movie-qa 承接。
- `movie-play` — 七段式结构且「顺序不可调换」，与评论区字数上限根本冲突。评论区的「XX 在哪看」由 movie-fact 覆盖。

3.5 列表类的生成与展示

涉及作品列表的技能有五个：movie-recommend-genre、movie-recommend-similar、movie-recommend-trending（均为 5~8 部规范）、movie-theater-scenarios（6~10 部）、movie-clips（4~6 条，最多 8 条）。

规则：服务端照常生成完整列表，评论区展示前 2~3 条 + 文字链，完整列表在 AI 助手页看。

这样跳转 B 提供的是实质增量——从 2~3 条到完整列表，加上全部作品卡。若服务端只生成 2~3 条，用户点「去 AI 助手看完整回复」跳过去看到的还是同样内容（只多作品卡），跳转动机不成立。

按评论区极简格式（片名 + 15 字内理由）实测字数：

部数	可见字数（含开头一句）	是否能在 100 字内完整展示
2~3 部	约 60~80 字	是
5 部	约 130 字	否，会被截断
8 部	约 210 字	否，会被截断

四、输出约束（Prompt）

以下内容随场景上下文注入，置于作品信息之后。可直接使用。

重要前置条件：段落标题必须沿用常量「## 场景信息（用户正在观看）」，评论区标识写在段落正文内。

代码块

```
1  ## 场景信息（用户正在观看）
2  - 当前场景：视频评论区
```

- 当前作品：《{作品名}》
- 频道：{频道}
- 当前集数：第 {N} 集
- 整部作品简介：{简介}
- 当前集简介：{当前集简介}
- 主演阵容：{主演}

评论区回答规则（优先级高于技能自身的格式规范）

一、长度与排版

- 不涉及作品列表的回答：可见文字控制在 150 字以内，越短越好。
- 涉及作品列表的回答（推荐、找片、合集）：可见文字控制在 220 字以内。
- 作品卡占位符不计入字数。
- 纯文本作答，不使用 Markdown 标题、分区标题、emoji 分区、加粗小标题。
- 不写"以下是..." "为你整理了..."等开场白，直接给结论。
- 第一句必须是完整结论——回答可能被截断展示，关键信息不得后置。

二、防剧透（最高优先级）

- 你的回答将公开展示在评论区，所有用户可见。
- 当前作品进度为第 {N} 集。严禁提及第 {N} 集之后才出现的剧情、人物命运、感情线结果、身份反转、结局走向。
- 用户询问的答案若在第 {N} 集之后，回答"这个悬念需要继续追剧才能揭晓"，不得暗示倾向、不得用"据说""有人猜"等方式变相透露。
- 无法确认某信息是否属于当前进度时，一律按剧透处理、不提供。

三、作品列表类问题（推荐、找片、系列检索、合集）

- 作品数量按技能自身规范执行，不因评论区场景减少。
- 每部只写片名和一句不超过 15 字的说明，不列主演、不列评分、不列上线时间、不列年份、不分条编号。
- 每部作品占一行，行与行之间不加空行。
- 最重要、最推荐的排在最前——列表可能只展示前几条。

四、系列/IP 类问题

- 保留系列与单部的区分：问整个系列时说清有几季/几部；问某一季时先答这一季，再简单带出其他季。
- 不使用分区标题，不使用引号包裹系列名，按上一条的列表格式平铺。

五、闲聊类问题

- 只做简短友好回应，1~2 句。
- 不进行角色扮演，不做性格测试或 MBTI 分析，不主动发起多轮互动话题。

六、结尾

- 正文以完整陈述句自然结束。
- 不输出任何互动提问、追问引导、"要不要我帮你..."式结尾。
- 不输出"相关短视频"分区。

4.1 几条约束的设计意图

「**第一句必须是完整结论**」：回答可能只展示前 100 字，把结论放在句首可保证截断后信息仍然可用。

「**作品数量不因评论区减少**」：服务端生成完整列表、前端只展示前 2~3 条，跳转才有实质增量。若服务端就只生成 2~3 部，跳转后看到的还是同样几部，用户没有点击动机。

「**每部作品占一行，行与行之间不加空行**」：为前端按条目边界截断服务。行边界清晰前端才能准确切分，不至于截在某部作品的中间。

闲聊收窄写在 Prompt 里而不是改 SKILL.md：casual-chat 规范只有 13 行且被其他场景共用，改 SKILL.md 会影响 AI 助手页的闲聊体验。场景约束优先级高于技能规范，写在这里即可。

列表类 220 字不是硬阈值：5 部约 130 字、8 部约 210 字，220 给 8 部留余量。真正兜住展示体验的是前端截断，Prompt 上限只防止模型写出长篇推荐语。

4.2 两个必须用代码关闭的模块

结尾互动与猜你想问由两个独立 LLM 模块在主答案结束后生成，写 Prompt 无效——主答案模型已被禁止输出相关标记，模块不从 Prompt 取指令。

- **结尾互动**是直接拼进正文流的文本，客户端无法过滤，且会占用字数预算 → 必须走模块开关关闭。
- **猜你想问**是终包独立字段，客户端可不渲染 → 走输出层置空即可。

五、作品卡占位符

作品卡以占位符 `{{qipuid:N}}` 的形式随正文一起下发。评论区不展示作品卡，前端把占位符过滤掉、只留作品名；跳转时把未过滤的原文带给 AI 助手页，由 AI 助手页渲染完整卡片。

六、防剧透

剧透边界为客户端回传的当前集：回答不得提及该集之后才出现的剧情、人物命运和关键转折。约束通过场景 Prompt 下发（见第四章「二、防剧透」），并声明为最高优先级。

评论区公开可见，一条剧透回复的影响面是整个楼层的所有读者，因此无法判断是否属于当前进度时一律按剧透处理。

七、缓存隔离

最终答案缓存里有一类「全局缓存」，key 只由问题文本构成，不含作品标识。评论区的问题天然高度雷同（「一共多少集」「谁演的」「什么时候更新」）且强依赖当前作品，如果沿用这条路径，就会出现《庆余年》评论区的答案被《狂飙》评论区命中——跨作品串答案，属于线上事故。

要做的事：让评论区请求不落全局缓存。 除了串作品，评论区答案还带剧透基数（同一问题在不同集数下答案本应不同）和评论区专属的长度、格式约束，这些也都不该流向其他场景。

同时路由后兜底产生的固定拒答话术也不能写入缓存，否则用户换个场景问同样的话会拿到「这个问题在评论区暂时回答不了」。

具体落点、可选的 scope 及各自的 key 区分度见 12.5。

八、内容安全与拒答

内容安全按线上现状执行，不新增审核链路，依赖 `sensitive-topic` 技能命中拒答与全局内容安全规则两层防护。该技能由路由模型语义判定、非硬过滤，存在漏判概率，而评论区公开可见、漏判后果比一对一问答更严重，因此建议上线后对评论区拒答命中情况单独埋点，积累数据后再评估是否加固。

`sensitive-topic` 的拒答不走统一话术，更不能加跳转链——把敏感问题引流到另一个入口去回答是安全事故。前端需要按话术文案区分这两类拒答。

被排除技能的拒答话术统一为一句「这个问题在评论区暂时回答不了」，前端在其后追加跳转 A 的文字链。不按技能分类解释边界，理由与文案取舍见 12.6。

九、耗时预期

评论区关闭两个引导模块后整体耗时低于常规场景，主要收益来自省掉模块等待与两次 LLM 调用。

环节	常规场景	评论区
引导模块 LLM 调用	模块 A + B 两次并行调用	不发起
答案结束后等待模块	最坏约 2.5s（等待预算上限）	0（主要收益）
答案生成	完整长度	字数受限，输出 token 更少

模块必须关闭，否则评论区反而更慢。 模块等待预算配置为 2500ms，实测其代价只落在答案本来就短且快的请求上（64~350 字场景，答案约 4.6~6s 完成而模块约 6.2~7.2s 才就绪）。评论区的短答案恰好落在这个最坏区间——答案越短，净等待越长。

十、客户端交互约定


字段 / 行为	约定
pageContext.pageName	固定传「评论区」
pageContext.mainContentId	当前集的 qipuld（服务端据此解析作品与集序号）


sid (conversationId)	评论楼层 ID，同楼层多次 @ 共享以支持追问
占位符处理	评论区展示时按 <code>/\{\{\qipuid:\[^}\]*\}\}/g</code> 过滤；原文需保留供跳转使用
截断（问答类）	可见文字超 100 字截断，回退到最近句号
截断（列表类）	保留前 2~3 条，回退到上一条条目结束处
跳转链出现条件	被截断 或 含作品卡占位符
跳转链文案	被截断时：「去 AI 助手看完整回复」；仅含作品卡时：「去 AI 助手看作品详情」
跳转 A 传参	仅原始问题
跳转 B 传参	原始问题 + 未过滤的回复原文（含占位符）
跳转 scheme	需新增，支持两种传参形态（待确认）

截断规则在两类回复间不同：问答类按字数回退到最近句号；列表类必须按条目边界切分，不能截在某部作品的片名或推荐语中间。这也是 Prompt 要求「每部作品占一行、行间不加空行」的原因。

十一、技术流程总览

以下标注评论区需要改造的全部环节，九个环节中八个在服务端、一个在前端。





环节	类型	代码位置	上线前置	实现细节
① 场景识别与注入	改造	<code>ChatController.putSceneContextPrompt</code>		见 12.1
② 路由候选收窄	改造	<code>SkillRoutingHook.buildSkillListSection</code>		见 12.2
③ 路由后兜底	新增	<code>SkillRoutingHook</code> (<code>applyTerminalCapabilityPolicy</code> 同层)	是	见 12.3
④ addon 不挂载	改造	<code>SkillAddonPolicy.determineAddonSkills</code>		见 12.7
⑤ 引导模块不 arm	改造	<code>GuidanceModuleArmInterceptor</code>		见 12.7
⑥ 输出约束 Prompt	新增	场景上下文注入		见第四章（全文）
⑦ suggestions 置空	改造	<code>BigTaodouGraphStreamAdapter</code>		见 12.7
⑧ 缓存隔离	改造	<code>FinalAnswerCacheService.resolveScope</code>	是	见 12.5
⑨ 前端展示与跳转	前端	—		见第十章

代码位置基于 master 分支（2026-08-04），行号可能随后续提交漂移，以方法名和常量名为准。图中蓝色为已有环节改造，红色为新增能力，黄色为 Prompt 约束，绿色为前端。

十二、各环节实现细节

本节汇总全部环节的实现级细节，包括前文第五、六、七、八章提到的注入规则、剧透落点、缓存与拒答实现。

12.1 环节①：场景识别与上下文注入

位置：`ChatController.putSceneContextPrompt`（`ChatController.java:1590` 三参重载）

新增 `isCommentSectionPage()` 判断：`pageName` 等于「评论区」且 `mainContentId` 非空。命中后调 `PlayContextUtils.resolveByMainContentId` 取作品上下文，拼装场景文本（含第四章的 Prompt 全文）写入 `GraphMetadataKeys.SCENE_CONTEXT_PROMPT`。

`resolveByMainContentId` 传当前集 `qipuld` 即可自动上溯专辑，一次拿到作品名、频道、整部简介、当前集简介、集序号、主演阵容和角色-演员映射。集序号取自 `metadata.title.series.episodeOrder`，为 -1 或 0 时回退到综艺的期次字段（`PlayContextUtils.java:176-185`）。

必须每轮注入。该方法默认只有首轮注入，非首轮直接 return（`:1615-1620` 的 `!isFirstTurn` 门控）。评论区支持同楼层多轮追问，落进该门控会导致第二轮丢失作品上下文与剧透基线。

实现范式已有现成的：同方法内的半播页卡片模式（`:1595-1613`）就是每轮注入——先判 `isHalfPlayCardMode && !isFirstTurn`，命中则拼装并 return，走在 `!isFirstTurn` 门控之前。评论区按同一位置、同一结构插入分支即可。

段落标题必须沿用常量：`AgentConfig.SCENE_CONTEXT_HEADING`（`AgentConfig.java:146`）=「## 场景信息（用户正在观看）」。下游按该标题做 extract 与 strip，改标题会让锚点失配。

12.2 环节②：候选技能收窄

位置：`SkillRoutingHook.buildSkillListSection()`（`SkillRoutingHook.java:682`），被 `:601` 拼进路由 system prompt。

评论区场景下只拼白名单内的 14 个技能（第一阶段 13 个不含 series-franchise），降低路由模型误判概率。

注意：路由 system prompt 走显式前缀缓存，技能列表属于可缓存的稳定前缀。裁剪列表会改变缓存前缀，评论区与常规场景将命中不同缓存条目——收窄候选降低误判的收益可能被缓存分裂带来的首 token 延迟部分抵消。若灰度实测负收益明显，可退化：不裁剪技能列表（放弃环节②），只靠环节③兜底拦截，功能正确性不受影响。

12.3 环节③：路由后兜底（上线前置）

这一环不可省略。原因是路由模型返回结果后还有一层确定性覆写：

`DETERMINISTIC_OVERRIDE_SKILLS`（`SkillRoutingHook.java:80`）在正则高置信命中时直接覆盖路由结果（判定点 `:460`），其 7 个技能全部在排除名单里：

play-album、play-clips、follow-album、subscribe-album、consumer-service、sleep-timer、battle-report

只做环节②的技能列表裁剪，这 7 个技能仍会 100% 绕过白名单。相关正则定义在

`SkillIntentRouter.java`，其中两条在评论区的误命中率明显更高：

- `BATTLE_REPORT_INTENT` (`SkillIntentRouter.java:97`，判定处 `:498`) 用无锚定的 `find()` 匹配，「这剧战报好看」会命中
- `WANT_WATCH_EPISODE_INTENT` (`:254`，判定处 `:411`) 匹配「我要看第 N 集」，这是评论区极常见的发言

实现：在 `applyTerminalCapabilityPolicy` (`SkillRoutingHook.java:309`，调用点 `:291`) 同层新增评论区校验，路由结果落定后若命中排除名单，写入带固定话术的 `TerminalAnswer` 直接终止。
`TerminalAnswerHolder.TerminalAnswer.skipFinalAnswerCache` (`TerminalAnswerHolder.java:25`) 必须置 `true`，写侧在 `BigTaodouGraphStreamAdapter.java:786` 据此跳过缓存写入。范式参照现有的 `ClientCapabilityPolicy` (车载端不支持下载，`:311-324`)。

拒答话术见 12.6。

12.4 作品卡占位符的注入规则（对应第五章）

占位符有两条产生路径，设计约束前必须分清。

路径一：模型直接输出。少数技能在 `SKILL.md` 里显式要求模型写出占位符（如 `live-service`、`subscribe-album`、`follow-album`）。这类可以用 Prompt 约束数量与位置。评论区白名单里没有这类技能，因此这条路径与评论区无关。

路径二：服务端按引用与书名号自动注入。主要路径在 `ReferenceDeltaHandlerService`，模型只写书名号，服务端按 `refIndex` 和标题匹配注入占位符。相关规则：

- `FALLBACK_ELIGIBLE_SKILLS` (`ReferenceDeltaHandlerService.java:43-45`) = `movie-recommend-genre`、`movie-recommend-trending`、`movie-recommend-similar`、`movie-play`、`movie-identify`、`series-franchise`。所有挂接指令未命中时，按书名号标题兜底补挂。
- `NO_BODY_QIPUID_SKILLS` (`:51`) = `movie-qa`、`movie-fact`。正文一律不挂 `qipuld` (判定 `:938-944`)，只在「相关短视频」区块内放行——评论区关了短视频区块，所以这两个技能不会通过此路径挂占位符。
- `webSearch` 来源的引用只对 `movie-recommend-genre`、`movie-recommend-trending`、`series-franchise`、`movie-identify` 关联 `qipuld` (`:920-928`)。
- `movie-clips` 和 `plot-point` 不链接来自实体工具 (`searchMovie` / `discoverMovies` / `searchEntity` 等) 的结果 (`:930-936`)。

由此得到三条结论：

1. 荐片类与 `series-franchise` 生成 N 部就会挂 N 个占位符，Prompt 写数量上限无效，评论区侧靠前端展示截断控制，AI 助手页照常渲染全部卡片。
2. `movie-qa`、`movie-fact` 正文本就不挂占位符，评论区又关短视频区块，所以这两个技能的评论区回复通常不带作品卡——跳转链只在超长时出现，不会因占位符触发。

3. `{{qipuid:N}}` 原样下发到客户端，跳转 B 直接传即可，无需新增答案存储与回捞接口。

补充一条与回捞相关的坑：graph checkpoint 会把 `{{qipuid:N}}` 替换成「（来源已引用）」（`CheckpointReferenceSanitizer.java:42-43,108`），所以若将来改为服务端回捞，不能从 checkpoint 取原文。

12.5 环节⑧：缓存隔离（上线前置，对应第七章）

位置：`FinalAnswerCacheService.resolveScope`
（`FinalAnswerCacheService.java:1079`）

串答案是怎么发生的。`resolveScope` 有两条路径会返回 `GLOBAL_QA`：

1. `isCacheEligibleSkill(skillName)` 命中（`:1088`）。名单来自云配 `DEFAULT_READ_LEGACY_SKILLS`（`FinalAnswerCacheCloudConfigListener.java:31-40`），共 8 个：movie-recommend-trending、movie-theater-scenarios、series-franchise、movie-play、movie-play-external、movie-fact、celebrity-gossip、movie-identify。其中 movie-fact、movie-identify、movie-theater-scenarios、series-franchise、movie-recommend-trending 五个在评论区白名单内。
2. `isGlobalQaQuestion` 命中且 `isContextDependentByRule` 判非上下文依赖（`:1094-1108`）。

`GLOBAL_QA` 的 key 只由「`global` + 归一化 message + `MODEL_TAG`」构成（`:1021-1029`），不含页面标识、不含作品 ID。

串答案路径：用户在《庆余年》评论区间「这剧一共多少集」→ movie-fact 命中路径 1 → 写 `GLOBAL_QA`；另一用户在《狂飙》评论区间问同一句 → 命中同一条缓存 → 拿到《庆余年》的集数。

还有一条容易漏的读路径：scope 非 `GLOBAL_QA` 时，`getOrCompute` 会走 `lookupGlobalHitByFallback`（`:320-321`，实现 `:1208`）用 global key 反查 L1/L2。也就是说单纯让 scope 返回 `USER_RECO` 并不能完全隔离，评论区分支必须同时短路这条 fallback 查询。

实现方式：在 `resolveScope` 开头、`isHalfPlayOpeningPlot` 判断（`:1083`）附近插入评论区分支。两个选项：

- 返回 `USER_RECO`（最小改动）。注意 `USER_RECO` 的 key 由 uid、qyid、agentType、platform、归一化 message、`digestHistory(history)`、`MODEL_TAG` 构成（`:1031-1041`），不含 **conversationId**——同楼层追问能否命中取决于历史摘要是否一致，跨作品不会串（不同作品的场景上下文进入历史后摘要不同）。同时 `isCacheEnabledForScope`（`:1075`）对 `USER_RECO` 返回 false，即不写不读，配合短路 fallback 后等价于评论区完全绕过缓存。

- **新增评论区专属 scope**（如 `COMMENT_SECTION`），key 里带 `mainContentId` 与集序号。收益是同一楼层同一问题可以命中、跨作品与跨集天然隔离；成本是要新增 key 构造、TTL 和读写开关三处分支。

第一阶段建议先按 `USER_RECO` 落地（不读不写，最安全），把专属 scope 作为后续优化。

另外环节③的固定话术必须置 `skipFinalAnswerCache=true`，见 12.3。

12.6 拒答话术的设计（对应第八章）

被排除的技能有个共同点：它们在 AI 助手页里都能正常执行或回答——端上操作在 APP 内可执行，个人数据类有账号态可用，场景无关类本就是 AI 助手的常规能力。所以拒答不是能力缺失，只是当前入口不支持，把用户导向能解决问题的地方比分类解释更有价值。

话术统一为一句话，前端在其后追加跳转 A 的文字链：

代码块

```
1  这个问题在评论区暂时回答不了
```

好处有三：不必维护技能到多组话术的映射，新增技能时无需同步归类；评论区公开可见，一句克制的说明比逐类解释边界更得体；把「答不了」转成一次有效的入口引流。文案上刻意不说「我不会」（是入口限制而非能力缺失），也不给「聊聊这部剧的剧情吧」这类留在评论区的引导——它与跳转链方向相反。

跳转 A 传参只带原始问题，AI 助手页重新发起提问。

`sensitive-topic` 例外：不走这套话术，也不加跳转链，前端按话术文案区分渲染。

12.7 环节④⑤⑦：输出模块关闭

环节④：addon 不挂载

位置： `SkillAddonPolicy.determineAddonSkills`
（`SkillAddonPolicy.java:100`）

评论区不挂载 short-video addon。 `SkillRoutingHook` 内部统一走私有包装 `determineAddonSkills`（`SkillRoutingHook.java:822-823`），共十余处调用点；除此之外还有 `SpeculativeCall1PromptBuilder.java:72`（投机执行链路）直接调静态方法，需确认投机链路上评论区请求的行为一致，否则可能出现主链路不挂而投机链路挂的情况。

环节⑤：引导模块不 arm

位置： `GuidanceModuleArmInterceptor`

评论区场景不 arm 模块 A/B，省掉两次 LLM 调用与最坏约 2.5s 的模块等待
（`GuidanceModuleProperties.waitBudgetMs=2500`），

`GuidanceModuleProperties.java:39`；云配键

`MOVIEAI_GUIDANCE_MODULE_WAIT_BUDGET_MS`）。模块 B 没有按技能排除的名单（模块 A 有），评论区需要的是按场景关闭，粒度与现有 `safetyRefusal` 一致。

环节⑦：suggestions 置空

位置：`BigTaodouGraphStreamAdapter`

输出层将 suggestions 置空，占位符原样下发不做剥离。现成范式是内容安全拒答：

`GuidanceModuleService.java:280-283` 在 `safetyRefusal` 时返回 `Pick.NONE`，`BigTaodouGraphStreamAdapter.java:724-726` 同步把 `followupLines` 置空。评论区按同一模式扩展，一处生效覆盖模块产出与正文提取两条链路。

注意结尾互动不能靠这里过滤：它是拼进正文流的文本

（`BigTaodouGraphStreamAdapter.java:696-700`），客户端无法剥离，必须按环节⑤关模块。

十三、实施路径

13.1 第一阶段：核心链路（不含 series-franchise）

技能范围：白名单 14 个中除 series-franchise 外的 13 个。

改造项：环节①②③④⑤⑥⑦⑧——场景识别与每轮注入、白名单收窄、路由后兜底、addon 与模块关闭、输出约束 Prompt、suggestions 置空、缓存隔离。

其中环节③路由后兜底与环节⑧缓存隔离是上线前置项，均不可省略。前者决定功能是否真的可用，后者关系到答案正确性。

13.2 第二阶段：前端承接与 series-franchise

前端：占位符过滤、两类截断规则、两类跳转链接入；AI 助手页支持展示外部传入的问答对并渲染作品卡（跳转 B），以及支持携带原始问题的落地提问（跳转 A）。

series-franchise 放开：该技能为 245 行强格式规范，模式 A/B 分型需保留而格式层需场景覆盖。上线前必须跑 benchmark 验证模型在场景约束下的格式遵循度（详见 14.3），若不达标需为评论区场景单独准备精简版规范。

13.3 第三阶段：体验优化

列表类的评论区专用格式调优、回复风格口语化、高频问题引导。评论区专属缓存 scope（见 12.5）。battle-report 与 calendar-service 的放开评估。

十四、风险与验证

14.1 两个上线前置项

项	不做的后果
环节③路由兜底	7 个排除技能绕过白名单 100% 落地，功能形同未收窄
环节⑧缓存隔离	跨作品串答案，线上事故

14.2 前缀缓存分裂

路由 system prompt 走显式前缀缓存，环节②裁剪技能列表会改变缓存前缀，评论区与常规场景将命中不同缓存条目。需灰度实测路由环节耗时与缓存命中率。

若实测负收益明显，退化方案：不裁剪技能列表（放弃环节②），只靠环节③兜底拦截。

14.3 series-franchise 格式覆盖验证

series-franchise SKILL.md 中的格式约束用了大量「违反即失败」级表述（模式 A 开篇首字符必须是「」、模式 B 必须接 ### 同系列其他作品、所有列表行必须挂 [n]、落笔前自检四条），与评论区场景约束直接冲突。需在放开前跑 benchmark 验证模型是否稳定遵循场景约束。

验证重点：是否仍输出 ### 分区标题、「」开篇、[n] 引用标号。若遵循度不足，退路是为评论区场景单独准备一份精简的 series-franchise 规范，而非依赖场景约束覆盖。

benchmark 工具在 ai-assistant-benchmark-master/，新增评论区场景到 scene_to_skills 后跑 python3 scripts/run_benchmark.py --scene <场景名>。

14.4 验证时的注意事项

绕开 LLM prefix-cache：验证 Prompt 改动效果时，相同问句会命中前缀缓存返回旧答案。改问句表述或换 conversationId。

投机执行链路：SpeculativeCall1PromptBuilder.java:72 也调 determineAddonSkills，验证环节④时需确认投机链路行为与主链路一致。

benchmark 回归：Prompt 改动影响 14 个技能的输出格式，列表类与 series-franchise 需重点回归。